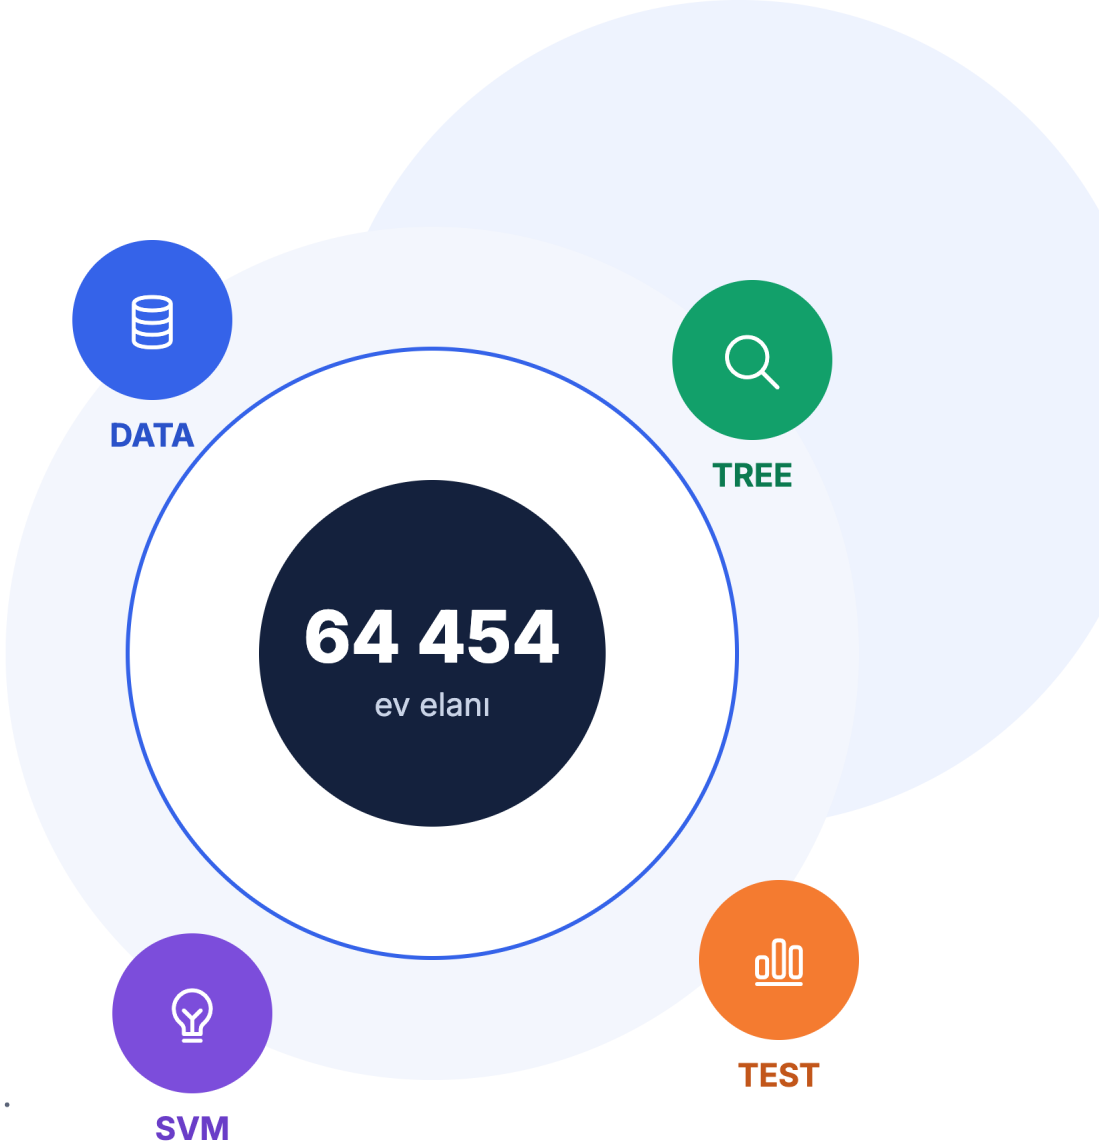
MLE-AI-201 / FINAL LAYİHƏ

Azərbaycanda ev qiymətlərinin proqnozu

64 454 bina.az elanı · sıfırdan Decision Tree və SVM

Regression | Classification | NumPy + sklearn

Üzv 1: Həsən Nurməmmədov · Üzv 2: Bulqeyis Məmmədova · Üzv 3: Ulvi İsmayılzadə · Üzv 4: Bakir Qəhrəmanov



PROBLEM / İKİ TAPŞIRIQ

Bir dataset, iki fərqli proqnoz

Eyni ev elanı həm qiymət, həm də premium sinif baxımından analiz olunur

TASK A / REGRESSION

Evin qiyməti nə qədərdir?

log(1 + qiymət) ilə öyrədilir; AZN-də MAE, RMSE və R^2 ilə ölçülür

BINA.AZ

TASK B / CLASSIFICATION

Ev premium sinfindədirmi?

Hədd: train median-ı, 210 000 AZN; precision, recall, F1, ROC-AUC

FEATURE-LƏR Sahə | Otaq | Mərtəbə | Məkan (lat/lng) | Torpaq sahəsi | Əmlak növü

ÜZV 1 · HƏSƏN NURMƏMMƏDOV

Data: təmizləmə, split və coğrafi bonus

data_prep.py

EDA skriptləri

geospatial_bonus.py

1

100 775 elandan 64 454 etibarlı nümunəyə

Dublikat, format, boş dəyər və leakage problemləri addım-addım həll edildi

100 775
xam sətir

↓

64 454
təmiz, təkrarsız elan

01 Dublikatlar	Eyni URL üçün son versiya saxlanıldı
02 Mətn → rəqəm	"120 m²", "6 sot" → m²; "5/9" → mərtəbə
03 Boş dəyərlər	Train median-ı; mənzildə torpaq sahəsi = 0
04 Leakage	unit_price, total_price silindi (qiymətdən hesablanır)
05 Valyuta	Bütün qiymətlər AZN; yoxlama aktivdir

Train-dən öyrən, test-ə baxma

Seed 42 ilə 70 / 15 / 15; bütün statistikalar yalnız train-dən

TRAIN · 70%	VALIDATION	TEST
45 118	9 668	9 668

Yalnız train

Median, one-hot sütunları və 210 000 həddi train-dən hesablanır, sonra val/test-ə tətbiq olunur

Validation = seçim

Bütün parametrlər yalnız validation nəticəsinə görə seçilir

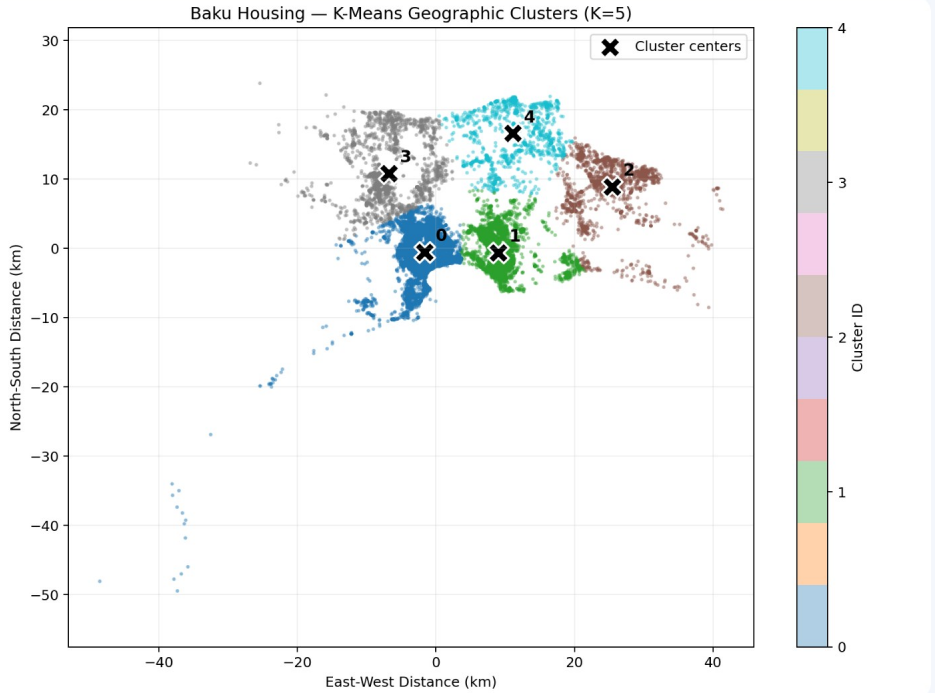
Test = bir dəfə

Test ən sonda, seçilmiş modellə yalnız bir dəfə ölçülür

Bakının xəritəsində 5 zona

k-means yalnız train koordinatları ilə öyrədilib

BAKI / GEO CLUSTERS (K = 5)



01 Koordinat → km

lat/lng train median-ı ətrafında kilometrə çevrildi

02 k-means, k = 5

Validation və test evləri ən yaxın mərkəzə verildi

03 Silhouette

k = 2 → 0.667, k = 5 → 0.581; k = 5 daha çox detal verir

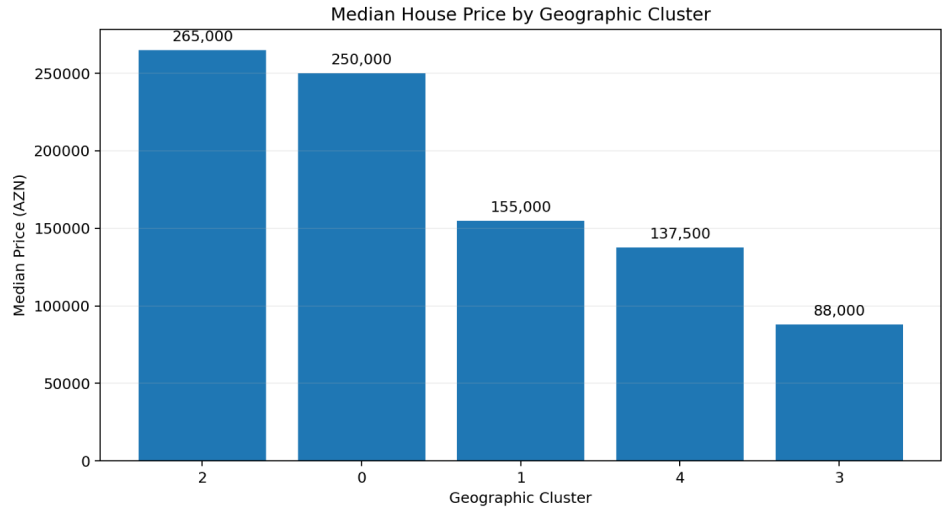
Hər nöqtə bir elan, rəng klasteridir, X klaster mərkəzidir. Analiz təsviridir, modelləri dəyişmir.

ÜZV 1 / BONUS: ZONALAR ÜZRƏ QİYMƏT

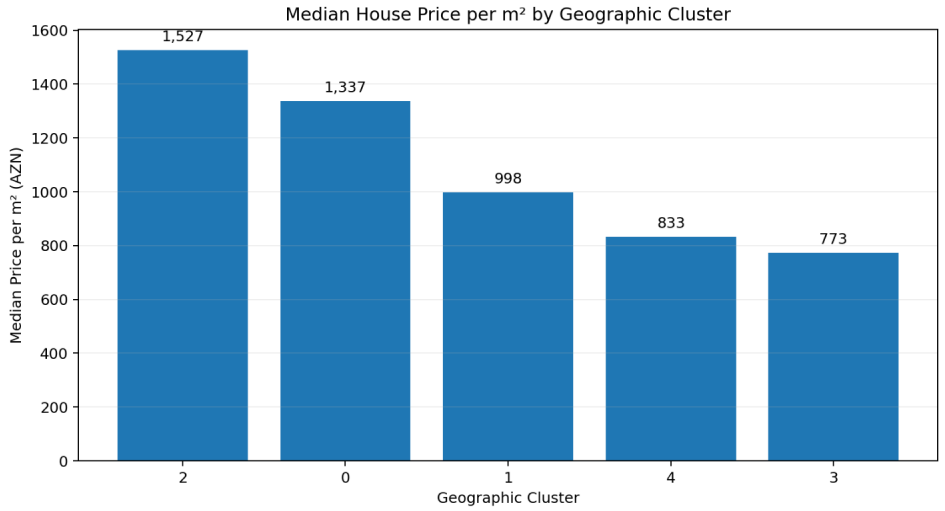
Yer qiyməti 3 dəfə dəyişir

Sahəni çıxanda da (m² qiyməti) zona fərqi qalır

MEDIAN QİYMƏT / KLASTER



MEDIAN QİYMƏT / M²



88 000 → 265 000 AZN: median qiymət 3× fərqlənir

773 → 1 527 AZN/m²: yer özü də qiymətə təsir edir

ÜZV 2 · BULQEYİS MƏMMƏDOVA

Decision tree və random forest, sıfırdan

decision_tree.py

test_tree.py

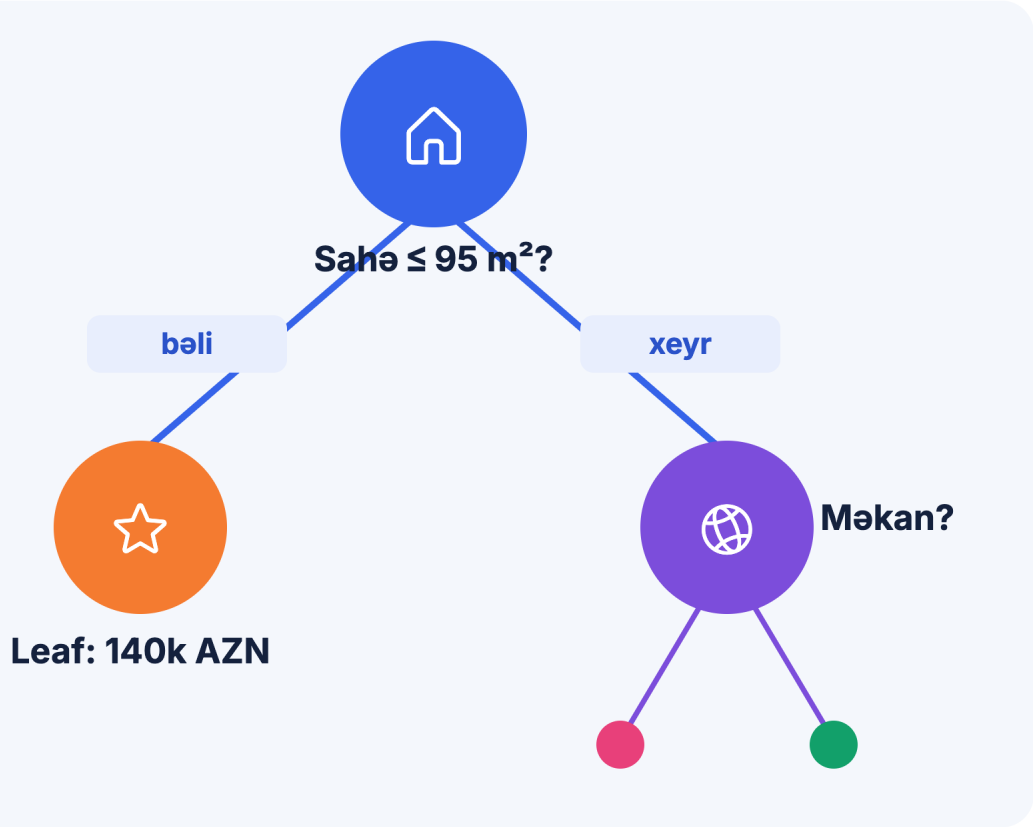
exp_tree.py

random_forest.py

2

Tree hər node-da ən yaxşı sualı verir

Impurity-ni ən çox azaldan sual seçilir, leaf-də proqnoz hesablanır



01 Impurity

Gini, entropy (Task B), MSE (Task A)

02 Split search

Ən böyük gain; sort + cumsum: 180× sürətli

03 Stop rules

max_depth, min_samples_split / leaf, min_impurity_decrease

04 Proqnoz

Leaf ortası və ya sinif ehtimalı (predict_proba)

9 test: sıfırdan yazdığımız tree işləyir

Kiçik nümunələrdə hər split sklearn ilə eynidir; real datada nəticə də eynidir

- ✓ Gini, entropy, MSE
- ✓ Class split = sklearn
- ✓ Regression split = sklearn
- ✓ predict, proba, importance
- ✓ 4 hiperparametr işləyir
- ✓ Ehtimal cəmi = 1
- ✓ Mətn etiketləri
- ✓ Sort + cumsum = sadə
- ✓ Float bug yoxdur

Real datada: validation R^2 0.735 və sklearn 0.736 · leaf sayı 3 527 və 3 524 · proqnozların 92.6%-i (Task B-də 99.5%-i) eynidir

Fərq: bərabər gain-də sklearn təsadüfi seçir, biz birincini; sklearn threshold-u float32 saxlayır

9 / 9

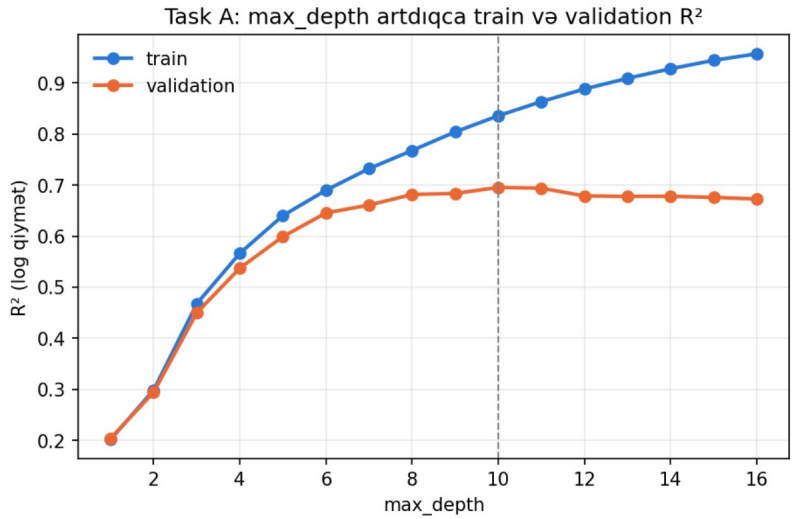
PASSED

python -m src.test_tree

Daha dərin tree hər zaman daha yaxşı deyil

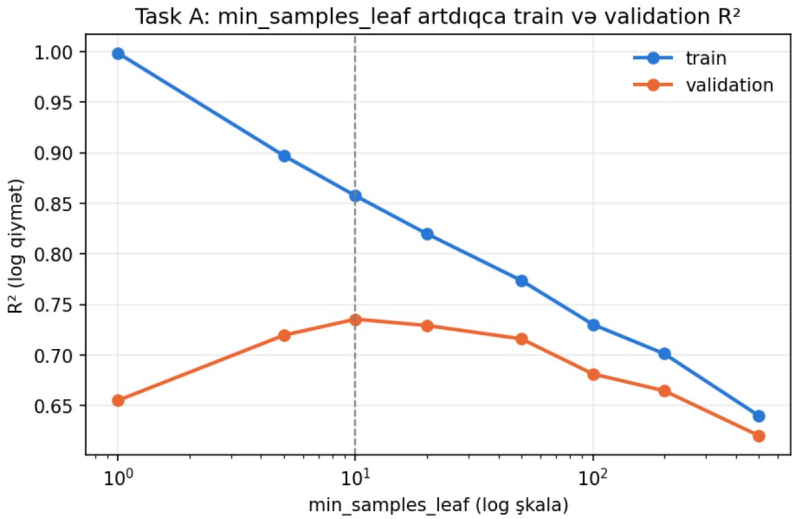
Train R^2 artır, validation R^2 müəyyən nöqtədən sonra düşür (Task A, log qiymət)

MAX DEPTH



Depth = 10: validation ən yüksək, 0.695

MIN SAMPLES LEAF

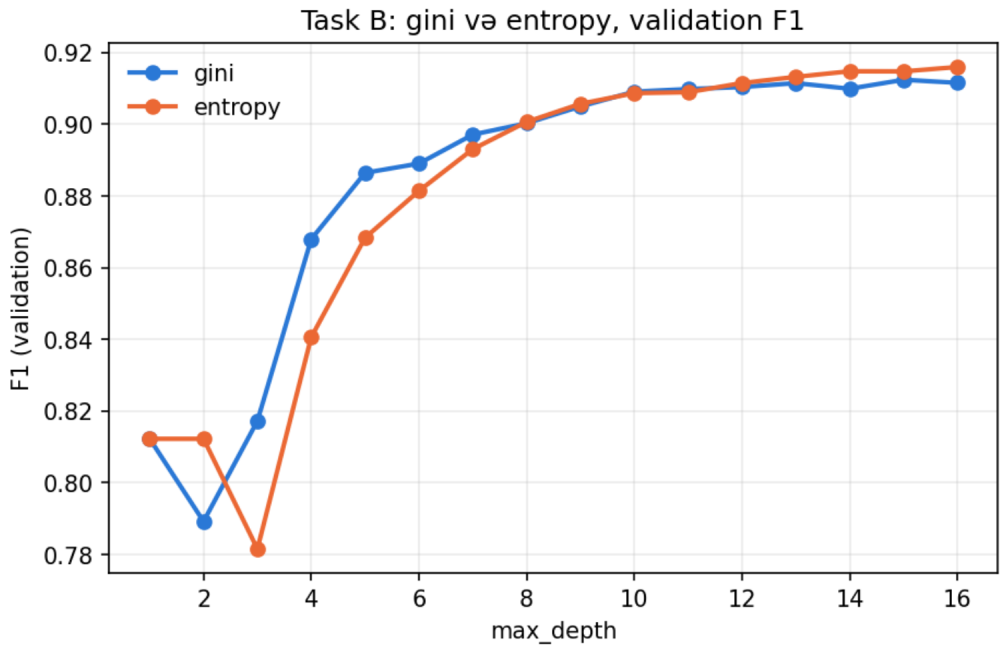


Leaf = 10: validation 0.735 (leaf 1-də 0.655)

İki fərqli ölçü, demək olar ki, eyni nəticə

Task B: premium tree-si iki impurity ilə öyrədildi, validation F1 müqayisə olundu

VALIDATION F1 · MAVİ = GİNİ, NARINCI = ENTROPY



GİNİ

$1 - \Sigma\, p^2$

ENTROPY

$-\Sigma\, p \cdot \log_2 p$

ƏN YAXŞI VALIDATION F1

0.912

Gini · depth 15

0.916

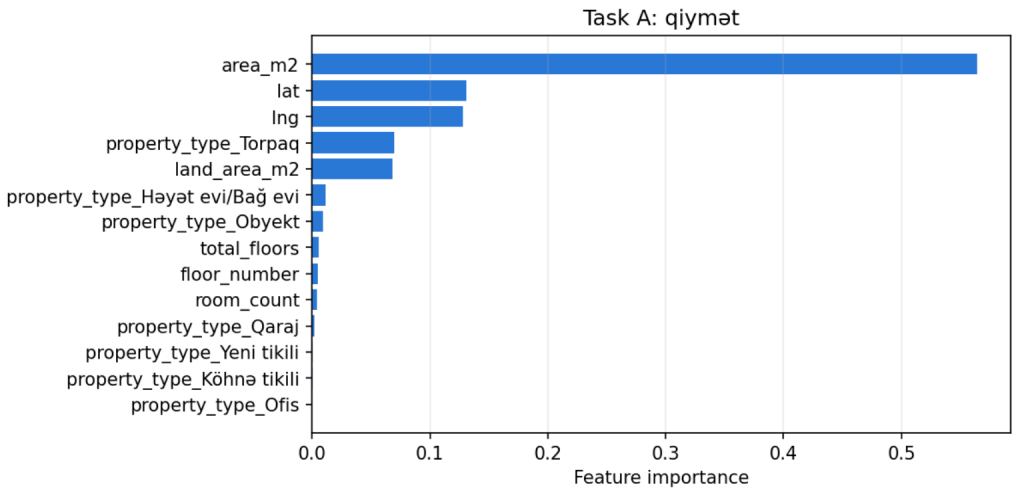
Entropy · depth 16

ROC-AUC isə depth 8–9-da ən yüksəkdir (~0.96): dərin tree 0/1 kimi çox əmin ehtimallar verir

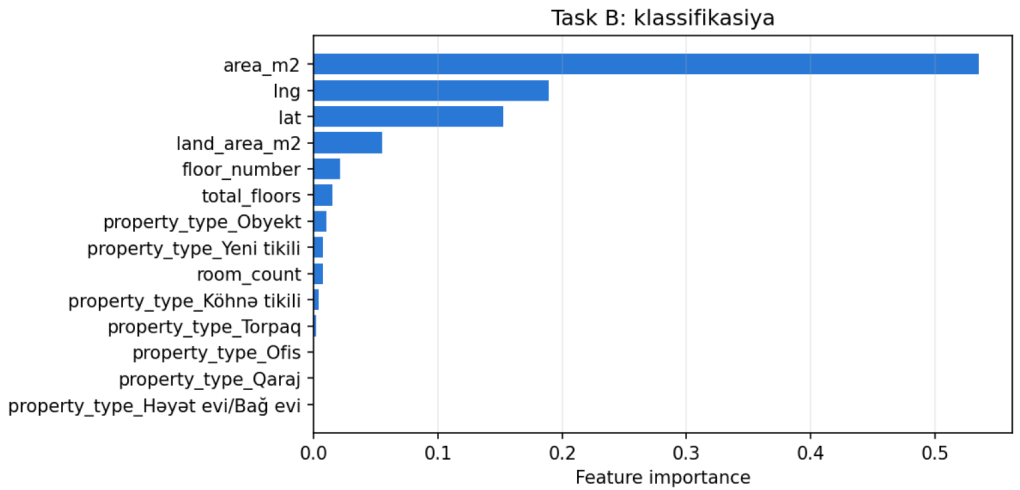
Qiymətin ən güclü siqnalları: sahə və yer

importance = hər split üzrə N_node × gain, cəmi 1 · proqnoz əlaqəsidir, səbəb deyil

TASK A · QİYMƏT



TASK B · PREMIUM



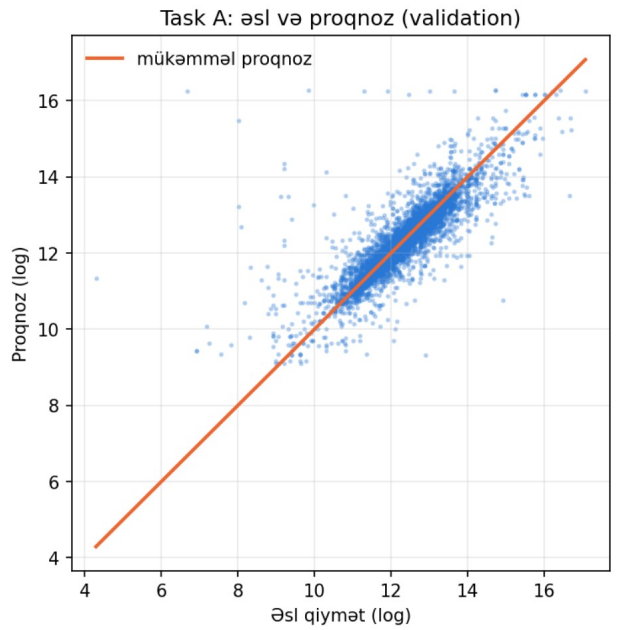
Sahə: 56% (qiymət), 54% (premium)

lat + lng: 26% (qiymət), 34% (premium)

Tree harada səhv edir?

Validation evləri: əsl və proqnoz log qiymət · narıncı xətt = mükəmməl proqnoz

ƏSL VƏ PROQNOZ



10.3%
median faiz səhvi

7–9%
orta qiymətli evlər

Ucuz və bahalı 20%: 14–17% səhv, nümunə azdır

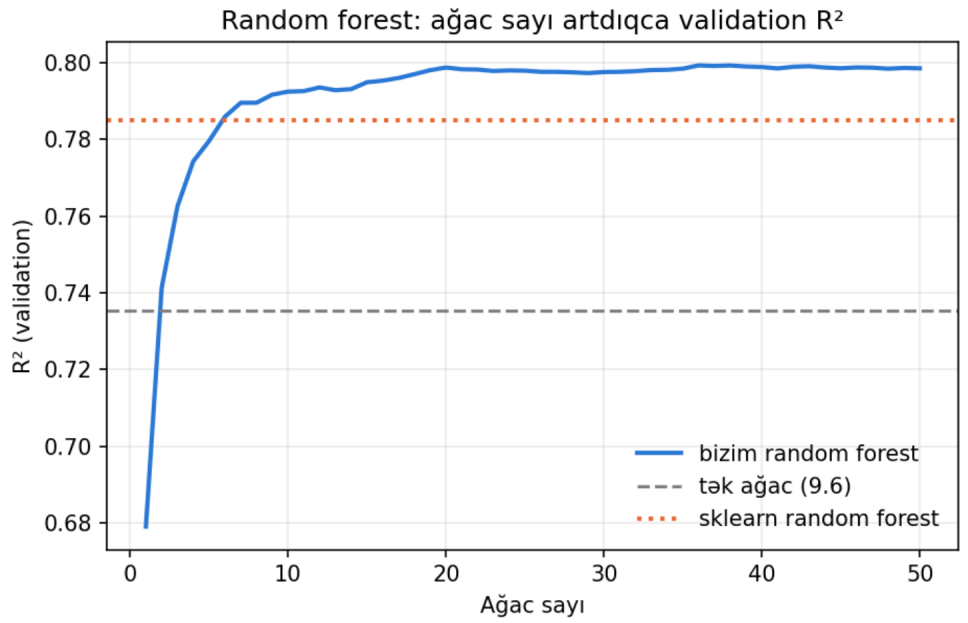
Ən böyük səhvlər data səhvidir: 800 AZN-ə 250 000 m² torpaq

Task B: 210 000 ± 10% evlərdə 31.9% səhv, uzaqlarda 5.9%

50 tree-dən ibarət random forest daha güclüdür

Bootstrap + hər split-də 2 təsadüfi feature → variance azalır

TREE SAYI ARTDIQCA VALIDATION R²





Ensemble

50 tree-nin ortalaması

VAL R²

0.735 → 0.799

SKLEARN RANDOM FOREST

0.785

Düzəliş: one-hot sütunlar node-da sabit idi (R² 0.609) → sabit feature-ləri keçdik → 0.799

ÜZV 2 / TEST NƏTİCƏLƏRİ

Tree sklearn ilə bərabər, random forest hamıdan yaxşı

Test bir dəfə, sonda · Task A log qiymətdə · get_splits() split-i

0.781 Tree R^2 (sklearn 0.781)

0.908 Tree F1 (sklearn 0.908)

0.832 Random forest R^2 F1 0.934

Model	MAE	R^2	F1	AUC
Bizim tree	0.202	0.781	0.908	0.938
sklearn tree	0.203	0.781	0.908	0.937
Bizim random forest	0.170	0.832	0.934	0.984
sklearn random forest	0.188	0.810	—	—

FINAL PARAMETRLƏR

Task A: depth None, leaf 10

Task B: depth 12, leaf 1, gini

CONFUSION (TASK B)

4 482 + 4 309 düzgün · 465 FP · 412 FN

ÜZV 3 · ULVİ İSMAYILZADƏ

Pegasos SVM və random Fourier features

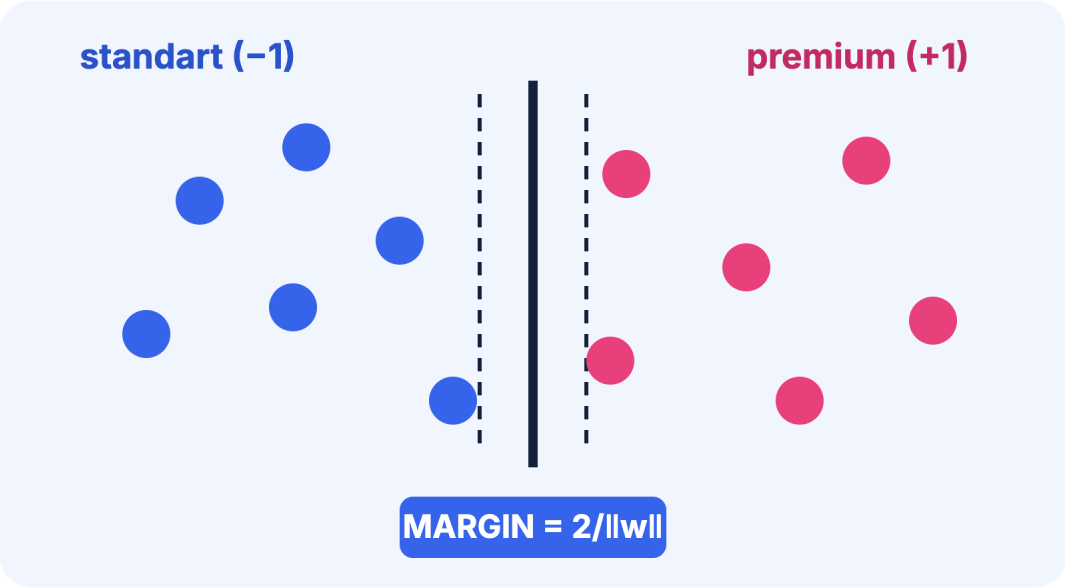
svm.py exp_svm.py test_svm.py

3

Pegasos: QP solver olmadan maksimum margin

Hinge loss səhvləri cəzalandırır, regularization modelin mürəkkəbliyini məhdudlaşdırır

$$J(w, b) = \lambda/2 \cdot \|w\|^2 + (1/n) \Sigma \max(0, 1 - y_i(w \cdot x_i + b))$$



01 Təsadüfi nümunə

Hər addımda 1 ev seçilir, hinge loss yoxlanır

02 Gradient update

η = 1/(λt): t artdıqca addım kiçilir

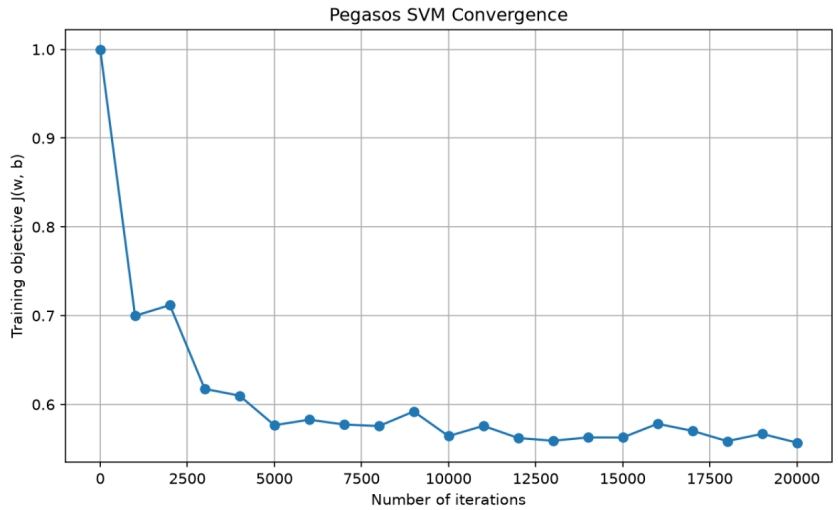
03 RFF, niyə?

256 cos feature RBF kernel-i təqlid edir; eyni xətti kod işləyir

Objective azalır, λ margin-i idarə edir

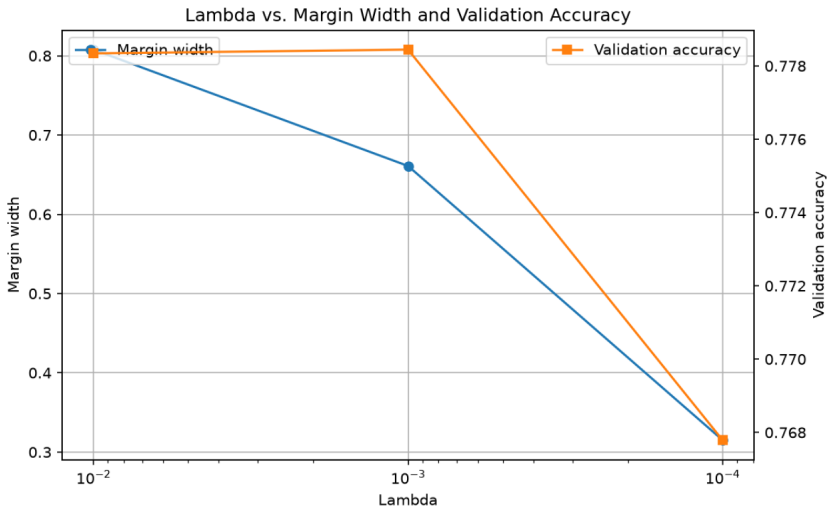
20 000 addımda konvergensiya; λ seçimi validation nəticəsinə əsaslanır

01 LEARNING CURVE



J(w, b): 1.0 → ~0.56, ~5 000 addımdan sonra sabit

02 LAMBDA SELECTION

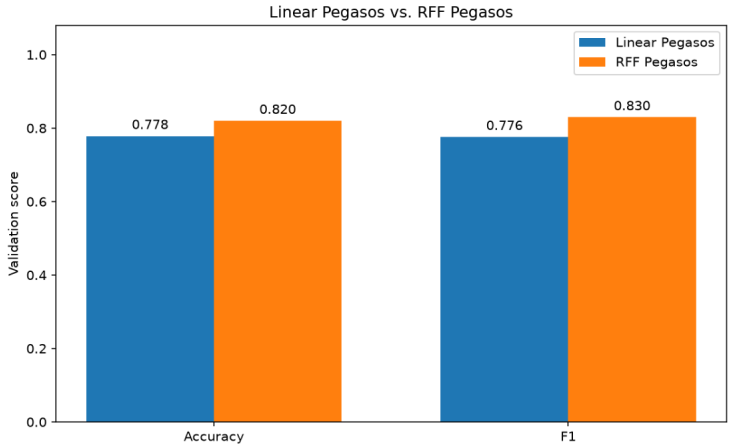


Böyük λ → geniş margin (~0.81); λ = 0.0001 → ~0.31

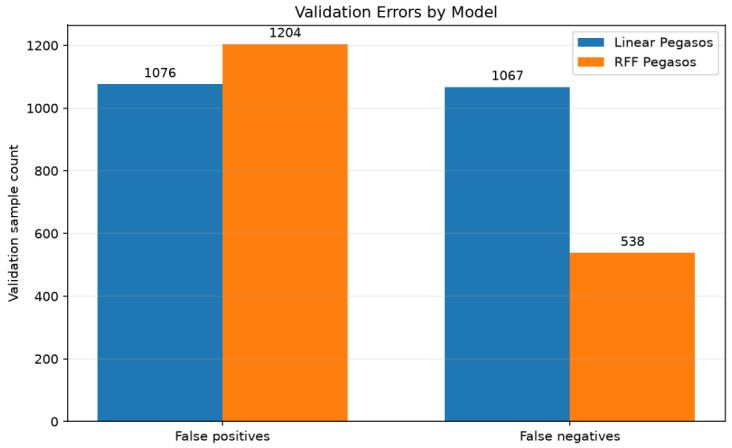
RFF xətti SVM-ə qeyri-xətti güc verir

14 orijinal feature → RFF: cos feature-lər → Eyni xətti Pegasos

XƏTTİ VƏ RFF · VALIDATION



SƏHVLƏRİN NÖVÜ



Validation F1: 0.776 → 0.830

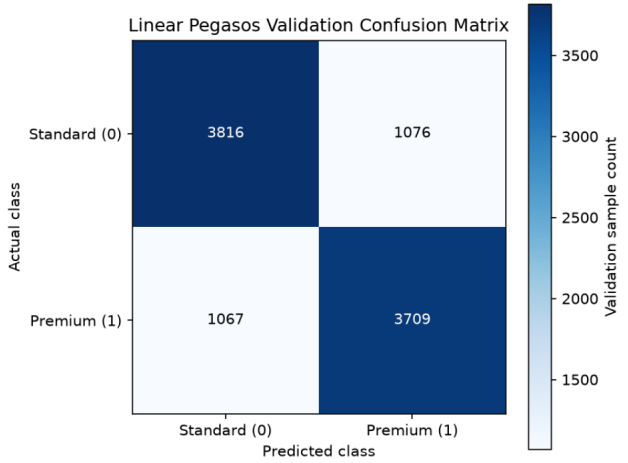
Qaçırılan premium: 1 067 → 538

ÜZV 3 / CONFUSION MATRIX

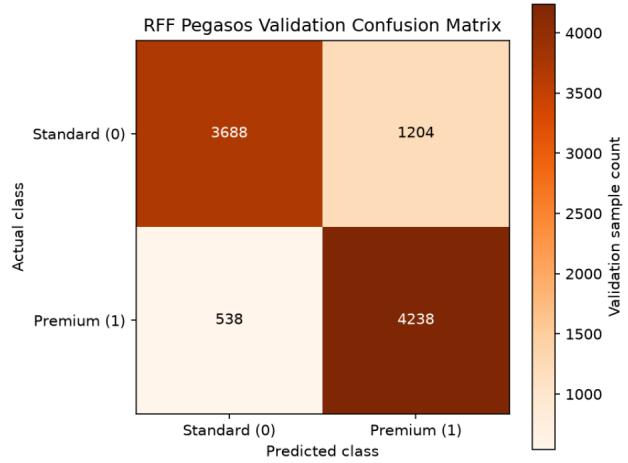
RFF premium evləri daha yaxşı tapır

Sətir = əsl sinif, sütun = proqnoz · diaqonal = düzgün · validation (9 668 ev)

XƏTTİ PEGASOS



RFF PEGASOS



Xətti: 2 143 səhv, iki tərəfə bərabər

RFF: 1 742 səhv, əsasən "səhvən premium"

ÜZV 4 · BAKİR QƏHRƏMANOV

İnteqrasiya: bir əmr, bütün nəticələr

run_all.py evaluate.py baselines.py tests/

4

Modelə gedən yol: 8 mərhələ, 1 əmr

run_all bütün modelləri eyni split-də öyrədir, seçir və bir dəfə test edir

01 Data collection · 100 775 sətir

02 Data cleaning · 64 454 elan

03 Train / Val / Test · stratified

04 Features · median, one-hot (train)

05 Train tree · gini / entropy / MSE

06 Train SVM · linear + RFF

07 Model selection · yalnız validation

08 Final test · bir dəfə + 3-fold CV

```
$ python -m src.run_all
```

~40 s · bütün rəqəmlər və şəkillər · seed 42 · 19 + 9 test keçir · requirements sabitdir

ÜZV 4 / FINAL TEST · EYNİ SPLIT

Öz modellərimiz sklearn ilə müqayisə olunur

Test: 9 669 ev, bir dəfə · CV = train-də 3-fold · Task A xətası AZN-də

0.904 Decision tree F1

0.806 RFF SVM F1

0.227 Qiymət R^2 (AZN)

TASK A / QİYMƏT

Model	MAE, AZN	R^2
Bizim tree	103 348	0.227
sklearn tree	103 550	0.227

Median xəta 24 700 AZN; log şkalada R^2 ~0.78

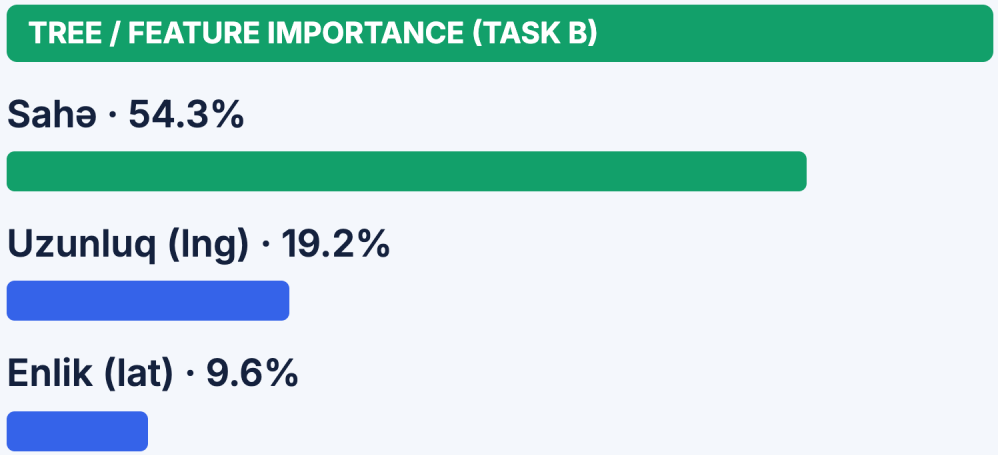
TASK B / PREMIUM

Model	F1	AUC	CV F1
Bizim tree	0.904	0.967	0.897
sklearn tree	0.904	0.967	0.897
Bizim RFF SVM	0.806	0.874	0.807
Bizim xətti SVM	0.777	0.826	0.774
sklearn SGD hinge	0.778	0.839	0.778

Tree yerə, SVM otaq sayına baxır

Final modellər, run_all · proqnoz əlaqəsidir, səbəb-nəticə deyil

TREE / FEATURE IMPORTANCE (TASK B)



Task A: sahə 59.0%, lat 11.8%, lng 11.6%

SVM / ÇƏKİLƏR (STANDARTLAŞDIRILMIŞ)

Feature	Çəki
Otaq sayı	+2.28
Növ: Ofis	+1.25
Sahə	+1.09
Növ: Qaraj	−1.65

lat/lng çəkisi kiçikdir (−0.21, +0.33): yer zonaları düz xətt deyil

ÜZV 4 / ERROR ANALYSIS · LÜKS EVLƏR

85 lüks ev ümumi xətanı böyüdür

Train-də belə nümunə azdır; tree yüksək qiymətləri sistemli şəkildə aşağı proqnozlaşdırır

3.64 mln

AZN orta xəta · 2.5 mln-dan bahalı 85 test evi

72 min

AZN orta xəta · qalan 9 584 ev · median 24.7 min

Lüks evlərin **90.6%**-i ucuz proqnozlaşdırılır: tree leaf ortasından bahalı qiymət verə bilmir. Ona görə AZN-də R^2 = 0.227.

Saniyələr içində öyrənir, nəticə sabitdir

3-fold CV yalnız train-də, hər fold öz preprocessing-i ilə

Fit vaxtı, saniyə

Model	Bizim	sklearn
Tree, qiymət	0.66	0.19
Tree, premium	0.89	0.17
Xətti SVM / SGD	0.11	0.18
RFF SVM	0.48	—

sklearn tree-si C ilə yazılıb: 3–5× sürətli

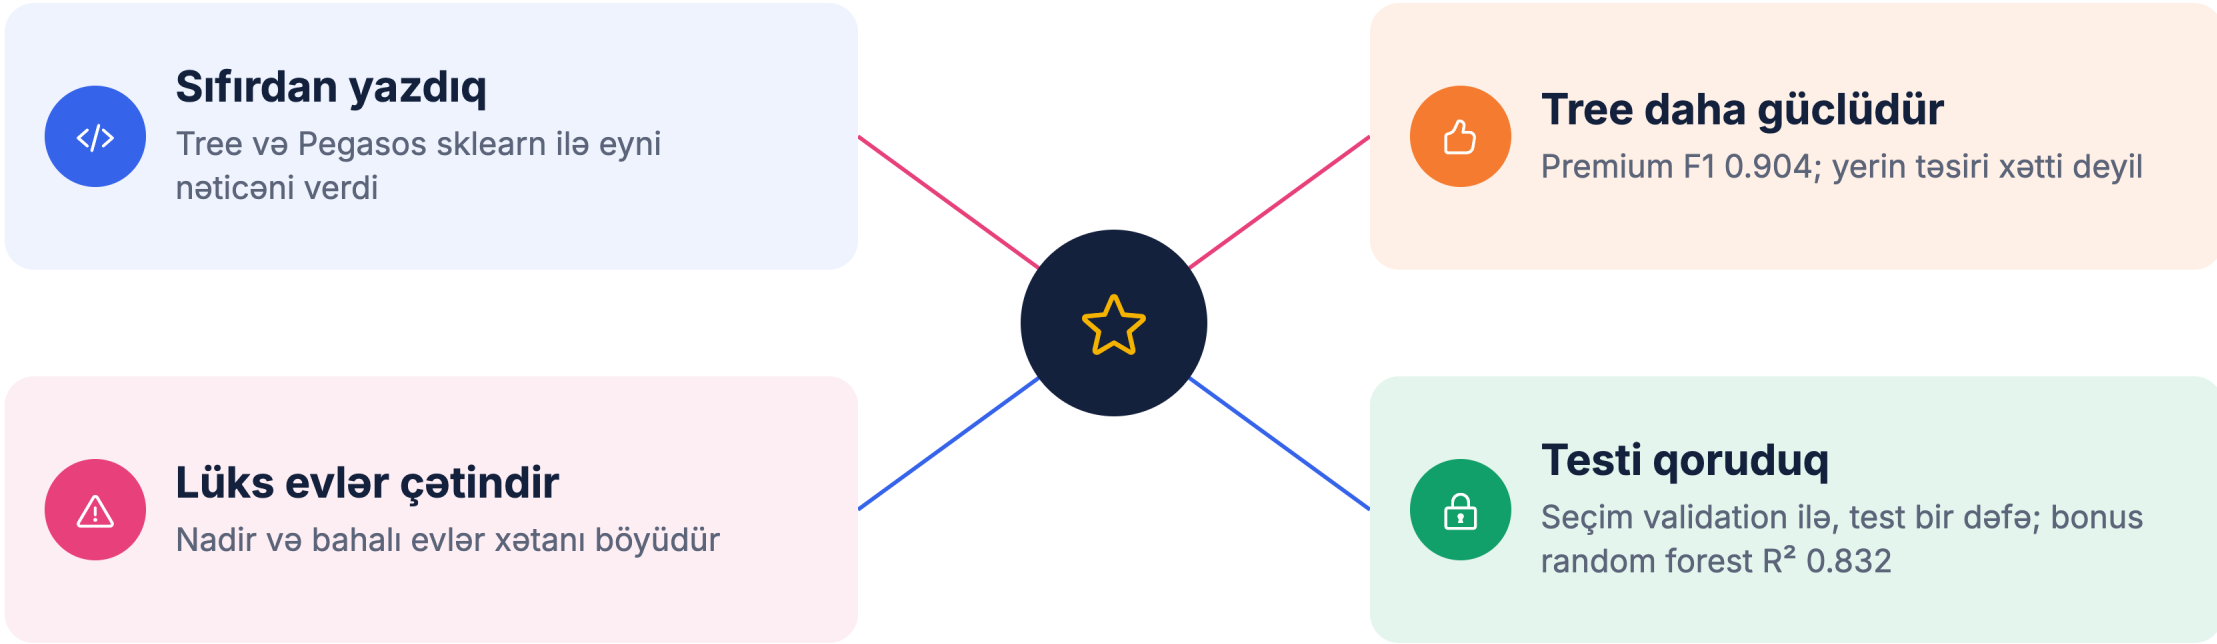
3-fold CV: mean ± std

Model	CV
Bizim tree F1	0.897 ± 0.001
sklearn tree F1	0.897 ± 0.001
RFF SVM F1	0.807 ± 0.006
Xətti SVM F1	0.774 ± 0.013
Tree log-RMSE	0.409 ± 0.018

FINAL TAKEAWAYS

Nə öyrəndik?

Məqsəd sadəcə model işlətmək yox, necə işlədiyini anlamaq idi



Üzv 1: Həsən Nurməmmədov · Üzv 2: Bulqeyis Məmmədova · Üzv 3: Ulvi İsmayılzadə · Üzv 4: Bakir Qəhrəmanov